

NORMALIZACION DE DATOS

Emilio Rearte

1) Introducción

Podemos definir a la normalización de datos como un proceso tendiente a identificar ciertas características estructurales en relaciones con problemas de actualización. Con su aplicación, una relación que reviste estas características se descompone progresivamente en otras relaciones estructuralmente más simples, que evitan dichos problemas, y sin pérdida de información alguna. En este sentido, podemos ver a la normalización de datos como un proceso reversible paso a paso para transformar una relación con características de estructura indeseables en estructuras deseables. Luego, como el proceso es reversible, no se pierde ninguna información durante la transformación.

2) Antecedentes sobre Normalización de datos

Actualmente, las seis formas normales más conocidas y que parecen tener un amplio consenso de aceptación entre los autores que abordaron el tema de la normalización de datos, son las que se definieron sobre el modelo relacional creado por Codd en el año 1972. Ellas son: la *primera*, *segunda* y *tercera* forma normal de Codd, publicadas en 1973; la *tercera* forma normal *fuerte*, que es una modificación que el ingeniero Boyce hiciera a la tercera forma normal de Codd en el año 1974; la *cuarta* forma normal descubierta en 1977 por Zaniolo, profesor de la Universidad de California; y la *quinta* forma normal descubierta en 1979 por Fagín, ingeniero de IBM. A partir de este año y durante toda la década del ochenta, fueron bastantes e importantes los trabajos desarrollados sobre el tema, pero todos ellos apoyados en estas seis formas normales tradicionales; ninguno produjo una modificación substancial de los conceptos básicos. Sin embargo, aportaron nuevos enfoques y observaciones que luego se tornaron de gran utilidad, destacándose entre ellos, los trabajos de Cárdenas, Date, Sharman, Robinson, Dean, Ullman y Smith. En este trabajo también tomamos como referencia para la investigación del tema las seis formas normales mencionadas, tratando de mantener sus versiones originales, utilizando la menor cantidad de definiciones posibles -sólo las necesarias- y definiendo un esquema común que proporcione una base conceptual homogénea, con el fin de hacer factible la comparación de los distintos enfoques y criterios aplicados por los citados autores.

2. 1) La Primera Forma Normal (PFN)

Una relación en estado original que contenga arreglos o ítems de grupo, presenta inconvenientes de actualización. Consideremos como ejemplo la siguiente relación:

PROFESORES (documento, nombre, domicilio, número de asignatura, nombre de asignatura, curso)

Suposiciones de contexto

- La relación describe las asignaturas dictadas por un profesor.
- El dictado de una asignatura es exclusividad de un profesor.

- Un mismo profesor puede dictar más de una asignatura.
- Cada asignatura tiene un curso propio.

Anomalías de actualización

- El número de asignaturas que podrá dictar un profesor estará limitado por el número de ítems fijado para las asignaturas en la relación.

- No podrá darse alta, baja o modificar los datos de una asignatura determinada independientemente del profesor que la dicta.

Condición de anomalías

La condición de anomalía en relaciones tales como la del ejemplo, se da por la presencia de grupos repetitivos entre sus atributos.

Grupos repetitivos: llamaremos así a aquellos grupos de datos compuestos por uno o más atributos de una relación que pueden adoptar más de un valor simultáneamente.

La presencia de grupos repetitivos en una relación ocasiona inconvenientes de actualización debido a la redundancia de datos generada por la falta de independencia de cada una de las ocurrencias del concepto representado por el grupo.

Definición de PFN

Para evitar las anomalías provocadas por grupos repetitivos, Codd creó la PFN cuya definición es la siguiente:

Una relación se encuentra en PFN si no contiene grupos repetitivos entre sus atributos.

Una relación que no se encuentra en PFN la llamaremos no normalizada.

Retomando el ejemplo, puede comprobarse que la relación PROFESORES no está en PFN, pues los atributos número de asignatura y curso conforman un grupo repetitivo. En consecuencia debe descomponerse de la siguiente manera:

PROFESOR (número-documento, nombre, domicilio)

ASIGNATURA (número-documento, número-asignatura, nombre asignatura, curso)

Observemos que las relaciones resultantes no presentan los inconvenientes de la relación original.

La primera forma normal según Cárdenas y Date

Una observación que estos autores apuntan sobre la PFN, es que cuando una relación posee grupos repetitivos, los dominios de los atributos que componen dichos grupos no son simples. Un dominio simple es aquél en donde todos sus elementos son atómicos; es decir, en la intersección de cada fila (tupla) con cada columna (atributo) siempre existe un único valor, nunca un conjunto de valores.

Veremos dos definiciones alternativas basadas en la misma observación, la primera pertenece a Cárdenas y la segunda a Date.

Definición 1: Una relación R se encuentra en PFN si todos sus dominios son simples.

Definición 2: Una relación R se encuentra en PFN si y solo si, todos sus valores subyacentes únicamente contienen valores atómicos.

Colorario de la PFN

Toda relación que pueda representarse como una tabla bidimensional está en PFN.

2.2) La Segunda Forma Normal (SFN)

Una relación a pesar de encontrarse en 1 FN, en algunos casos puede presentar anomalías de actualización. Consideremos por ejemplo la siguiente relación:

PEDIDOS (número de pedido, número de artículo, cantidad pedida, precio unitario)

Suposiciones de contexto

- La relación describe los datos de los pedidos de mercadería a la empresa XX.
- Un pedido puede incluir varios artículos.
- La cantidad pedida de un artículo en cada pedido es variable (no existen pedidos fijos a determinada frecuencia).
- El precio de un artículo es fijo (no varía de acuerdo a la cantidad pedida).

PEDIDOS

Nro. Pedido	Nro. Artículo	denominación	cantidad-pedida	precio-unitario
1	2	AA	3	4
1	4	LL	2	80
1	7	YY	7	30
2	4	LL	40	80
2	5	MM	70	20
3	1	XX	2	100
4	3	ZZ	1	40
4	8	NN	22	100
5	4	LL.	30	80
5	5	MM	2	20
5	7	YY	7	30

Como podemos observar, PEDIDOS se encuentra en PFN pues no contiene grupos repetitivos; sin embargo, presenta las siguientes anomalías de actualización.

Anomalías de actualización

Anomalías de alta:

Si la empresa incorporara un nuevo artículo al stock, no podrá dársele de alta hasta tanto exista un pedido concreto que lo incluya. Esto se debe a que *número de artículo* sólo es parte de la clave y la otra parte, *número de pedido*, justamente por ser parte de la clave, no puede por definición, adoptar valores nulos. En consecuencia, no podremos registrar información referida a un artículo nuevo, a menos que se cree un número de pedido ficticio para él.

Anomalías de baja:

- Si por cualquier razón se anulara un pedido, al dársele de baja, se perdería con él, toda la información referida a los artículos que comprendía. Y, en el supuesto caso, si el pedido dado de baja hubiera sido el único que incluía determinado artículo, no quedaría ningún antecedente de éste en la empresa.
- Si la política de la empresa fuera de no conservar archivos con información histórica, de manera que una vez procesados todos los pedidos deba dárseles de baja, entonces resultaría imposible conservar información referida a sus artículos, a menos que, como en el caso anterior, se cree un pedido ficticio que incluya a todos los artículos que vende.
- Si la empresa decidiera no vender más un determinado artículo, deberá dársele de baja tantas veces como pedidos haya para ese artículo. Además, no podrá completarse esta operación, sino se conocen todos los números de dichos pedidos.

Anomalías de modificación:

Si cambiara el precio o la denominación de un artículo, se deberán hacer tantas modificaciones de estos mismos datos como cantidad de pedidos haya para ese artículo. Además, no podrá completarse esta operación, sino se tiene conocimiento de todos los números de dichos pedidos.

Condición de anomalías

La condición de anomalía en relaciones tales como la del ejemplo, se da por la presencia de grupos parcialmente dependientes entre sus atributos. Para llegar a una definición de estos grupos, previamente veremos los conceptos de dependencia funcional y dependencia funcional completa.

Dependencia funcional: Un atributo B de una relación R es funcionalmente dependiente de un atributo A de la misma relación, si en cada instante, cada valor de A está asociado a no más de un valor de B dentro de R.

Decir que B es funcionalmente dependiente de A, es equivalente a decir que A identifica a B, pues conocido el valor de A automáticamente el valor de B queda determinado.

Dependencia funcional completa: Un atributo o una colección de atributos B de una relación R es dependiente funcional completo de otro atributo o colección de atributos A de la misma relación, si B es dependiente funcional del total de A, pero a la vez, no dependiente de ninguna subcolección de A.

Grupos parcialmente dependientes: llamaremos así a aquellos grupos de datos compuestos por uno o más atributos no primos de una relación, que no mantienen una dependencia funcional completa respecto de la clave.

La existencia de un grupo parcialmente dependiente en una relación produce inconvenientes de actualización, debido a la redundancia de datos generada por la falta de independencia del concepto representado por el mismo. En la relación del ejemplo, los datos referidos a un artículo (denominación y precio) se repiten para todos y cada uno de los pedidos que lo incluyen. Esto se debe a que están forzados dentro de la relación, a depender de número de pedido, cuando en realidad son independientes de él. En otras

palabras, los problemas de una relación que no se encuentra en SFN surgen a raíz de que se mezclan dentro de ella, diferentes tipos de información.


Definición de SFN

Para evitar las anomalías ocasionadas por grupos parcialmente dependientes, Codd creó la segunda forma normal cuya definición es la siguiente:

Definición: Una relación R se encuentra en SFN si se encuentra en PFN y cada uno de sus atributos no primos es dependiente funcional completo de cada clave candidata.

De la definición deducimos que si un atributo no primo es dependiente funcional completo de una clave candidata, entonces también debe serlo de todas las claves candidatas restantes que posea la relación.

Una relación que no está en SFN, representada gráficamente, adquiere la siguiente forma:



Si una relación no se encuentra en SFN debe descomponerse en dos o más relaciones que verifiquen esta condición. La descomposición debe hacerse eliminando la dependencia parcial en favor de la dependencia total; esto es, removiendo cada grupo de atributos no primos dependientes parciales respecto de cada clave candidata, a una relación aparte cuya clave estará formada por el atributo o conjunto de atributos primos, que los identifica y del cual dependen funcional y completamente. Aplicando esta regla tenemos:



Volviendo al ejemplo, podemos observar que la relación PEDIDOS no está en SFN pues precio y denominación, dos de sus atributos no primos, son sólo en parte funcionalmente dependientes de la clave concatenada *número de pedido-número de artículo*. Esto es así porque es suficiente para su identificación, conocer únicamente el número de artículo. No sucede lo mismo con cantidad pedida, otro de sus atributos no primos, pues ésta si necesita de los dos atributos de la clave para quedar totalmente identificada; es decir, no basta conocer solamente el número de pedido o el número de artículo para que cantidad pedida quede perfectamente determinada. En términos relacionales, *cantidad pedida* es del todo funcionalmente dependiente de la clave concatenada completa y única en la relación (número de pedido-número de artículo), en cambio *denominación* y *precio* no lo son, porque a pesar de depender funcional y completamente de ella -*todo atributo no primo al menos depende de su clave*-, también dependen funcionalmente de un subconjunto suyo (número de artículo). Por esta razón PEDIDOS no cumple con la SFN y debe descomponerse en dos relaciones donde sus atributos no primos dependan funcional y completamente de los respectivos subconjuntos de atributos primos, a través de quienes se identifican. Esto es así:

PEDIDOS (número-pedido, número-artículo, cantidad pedida)

ARTÍCULOS (número-artículo, denominación, precio)

PEDIDOS			ARTÍCULOS		
<u>número-pedido</u>	<u>número-artículo</u>	cantidad-pedida	<u>número-artículo</u>	denominación	Precio
1	2	3	1	XX	100
1	4	2	2	AA	4
1	7	7	3	ZZ	40
2	4	40	4	LL	80
2	5	70	5	MM	20
3	2	1	7	YY	30
4	3	1	8	NN	100
4	8	22			
5	4	30			
5	5	2			
5	7	7			

Podemos comprobar que cada una de las relaciones resultantes se encuentra en SFN.

La SFN según Cárdenas

Una observación importante que apunta Cárdenas sobre la SFN, también la menciona James Martin en su conocido libro “Organización de bases de datos”, es que una relación normalizada -en PFN-, sólo puede presentar las anomalías indicadas por la SFN, cuando la clave principal -no habla de claves candidatas- está compuesta por más de un atributo primo.

Definición: Una relación R se encuentra en SFN si se está en PFN y todos sus dominios no claves (no primos) son funcionalmente dependientes de la clave primaria (clave principal).

Corolario de la SFN

Si una relación se halla en PFN y su clave principal es simple, de hecho, también se encuentra en SFN y no hace falta aplicar ninguna definición.

2.3) La Tercera Forma Normal o Tercera Forma Normal Débil (TFND)

Una relación a pesar de encontrarse en SFN, en algunos casos puede presentar inconvenientes de actualización. Por ejemplo, consideremos la siguiente relación:

EMPLEADOS (número de legajo, número de documento, nombre, edad, categoría, salario)

Suposiciones de contexto

- La relación describe los datos de los empleados de la empresa XX.
- Existe un sólo escalafón con diez categorías.
- Varios empleados pueden poseer una misma categoría.
- Pueden existir categorías vacantes.

EMPLEADOS

<u>número-legajo</u>	<u>número-documento</u>	<i>nombre</i>	<i>edad</i>	<i>categoría</i>	<i>salario</i>
1	14.866.525	Pedro	27	3	100
2	13.421.722	Raúl	41	1	20
3	16.323.111	Ramón	22	9	820
4	10.852.323	Juan	30	3	100
5	4.853.211	Marcelo	55	10	900
6	9.862.111	Pedro	19	2	50
7	2.321.127	Juan	60	8	750
8	11.211.976	Raúl	28	5	450
9	17.891.365	Javier	23	3	100
10	17.428.012	Mauricio	21	2	50
11	1.101.302	Joaquín	65	9	820
12	21.013.421	Eduardo	17	1	20
13	13.082.179	Gustavo	41	6	600
14	20.000.101	Marcelo	18	2	50
15	10.421.021	Trenton	30	5	450

Podemos observar que la relación EMPLEADOS está en SFN pues todo atributo no primo depende funcional y completamente de cada una de las dos claves candidatas (número de legajo y número de documento); además, cada una de ellas está compuesta por un sólo atributo. Sin embargo, presenta las siguientes anomalías de actualización.

Anomalías de actualización

Anomalías de alta:

- Si la empresa decidiera *ampliar* su escalafón y crear una nueva categoría, deberá dársele de alta tantas veces como empleados la detenten. Además, no podrá completarse esta operación, sino se tiene conocimiento de todos los números de legajos ó números de documentos de dichos empleados.
- No podrá dársele de alta a la información referida a una categoría que pudiera estar vacante, hasta tanto se incorpore o ascienda un empleado a ella.

Anomalías de baja:

- Si la empresa decidiera *reducir* su escalafón y eliminar una categoría determinada, deberá dársele de baja tantas veces como empleados la detenten. Además, no podrá completarse esta operación, sino se tiene conocimiento de todos los números de legajos o números de documentos de dichos empleados.
- Si sólo existiera un empleado en una determinada categoría y éste por alguna razón renuncia, al darle de baja de la empresa, se perdería con esta operación, toda la información referida a dicha categoría.

Anomalías de modificación:

- Si la empresa decidiera aumentar el salario de una determinada categoría, deberá modificarse este mismo dato tantas veces como empleados la detenten.

Condición de anomalía

La condición de anomalía en relaciones tales como EMPLEADO, se da por la presencia de grupos transitivos entre sus atributos. Para llegar a una definición de estos grupos, previamente veremos el concepto de dependencia transitiva.

Dependencia transitiva: Sean A, B y C, tres atributos o tres colecciones de atributos de una relación R; si C es funcionalmente dependiente de B y B lo es de A, entonces C es funcionalmente dependiente de A. Ahora bien, si la correspondencia inversa no es simple, esto es, si A no es funcionalmente dependiente de B ó B no lo es de C, entonces se dice que C mantiene una dependencia funcional transitiva respecto de A.

Grupos transitivos: llamaremos así a aquellos grupos de datos compuestos por uno o más atributos no primos de una relación, que mantienen una dependencia transitiva respecto de la clave primaria. -

La existencia de un grupo transitivo en una relación ocasiona inconvenientes de actualización debido a la dependencia indirecta de sus atributos respecto de la clave y a la redundancia de datos generada por la falta de independencia del concepto que representa el grupo. Observemos que los datos referidos a una categoría (salario) están repetidos para todos los empleados que la detentan.

Definición de TFND

Para evitar las anomalías provocadas por grupos transitivos, Codd creó la tercera forma normal cuya definición es la siguiente:

Una relación R se encuentra en TFND, si se encuentra en SFN y además, cada uno de sus atributos no primos son dependientes no transitivos de cada clave candidata de R.

Si una relación no se encuentra en TFND debe descomponerse en dos o más relaciones que verifiquen esta condición. La descomposición debe hacerse eliminando la dependencia indirecta en favor de la dependencia directa; esto es, removiendo cada grupo de atributos no primos dependientes transitivos respecto de cada clave candidata, a una relación aparte cuya clave estará formada por el atributo o los atributos no primos que actuaron como intermediarios en la relación de dependencia.

Si consideramos nuevamente el ejemplo, podemos comprobar que la relación EMPLEADOS no se encuentra en TFND, pues el atributo no primo salario mantiene una dependencia funcional transitiva respecto de la clave a través del atributo no primo categoría, quién en éste caso actúa como intermediario. En consecuencia, EMPLEADOS debe descomponerse de la siguiente manera:

EMPLEADOS (número-legajo, número-documento, nombre, edad, domicilio, categoría)

ESCALAFON (categoría, salario)

La descomposición realizada es necesaria porque eventualmente pueden requerirse los datos de ESCALAFON independientemente de EMPLEADOS. Notemos que si bien salario es un atributo de un empleado, no depende de éste sino de la categoría que posea.

Un esquema ampliado de dichas relaciones sería:

EMPLEADOS
ESCALAFON

				<u>categoría</u>	salario
				1	20
				2	50
				3	100
				5	450
				6	600
				8	750
				9	820
				10	900
<u>número-legajo</u>	<u>número-documento</u>	nombre	edad	categoría	
1	14.866.525	Pedro	27	3	
2	13.421.722	Raúl	41	1	
3	16.323.101	Ramón	22	9	
4	10.852.323	Juan	30	3	
5	4.853.201	Marcelo	55	10	
6	9.862.111	Pedro	19	2	
7	2.321.127	Juan	60	8	
8	11.211.976	Raúl	28	5	
9	17.891.365	Javier	23	3	
10	17.428.012	Mauricio	21	2	
11	1101.302	Joaquín	65	9	
12	21.013.421	Eduardo	17	1	
13	13.682.179	Gusta	41	6	
14	20.000.101	Marcelo	18	2	
15	10.421.021	Trenton	30	5	

Podemos observar que ninguna de las relaciones obtenidas de la descomposición de EMPLEADOS presenta los inconvenientes planteados por la TFND.


La TFND según Date

Date define la TFND de la siguiente manera:


Definición: Una relación R se encuentra en TFND si los dominios no claves, si es que existe alguno, son a la vez, (1) independientes entre sí y (2) dependientes funcionales completos respecto de la clave principal.

Sin dudas, esta definición es una contribución valiosa a la normalización de datos, pues permite identificar rápida y eficazmente cuando una relación no está en esta forma normal, pero prescindiendo totalmente de las formas normales anteriores. Es decir, su aplicación es directa y produce automáticamente relaciones en TFND, sin necesidad de que éstas previamente se encuentren en PFN y SFN. Además, fundamentalmente, su importancia estriba en que resalta una característica deseable en toda relación en vías de ser normalizada: la independencia de cada atributo no primo en su relación de dependencia con la clave principal.

Una relación en TFND, analizada gráficamente, adquiere la siguiente forma:



Es decir, estará en TFND siempre que sus atributos no primos no participen de ninguna otra relación de dependencia que no sea la que los vincule directa y completamente con la clave principal. Por lo tanto, una relación que no está en TFND, reviste una forma parecida a la siguiente:



Cuando esto sucede, la relación debe descomponerse formando relaciones aparte con cada grupo de atributos no primos dependientes funcionalmente. Esto es así:



Observemos en este ejemplo, que los atributos causantes de conflicto -en este caso d- y que deben removerse a una relación aparte, son los apuntados por más de una flecha. Esto revela lo que afirmábamos anteriormente cuando nos referíamos a la condición de anomalías de una relación que no se encuentra en TFND, y es que los inconvenientes de actualización se presentan siempre que se detectan grupos de atributos no primos repetidos perjudicialmente, para más de un valor de la clave.

Corolario de la TFND

Una relación en SFN que no posee atributos no primos o a lo sumo posee uno, siempre estará en TFND.

2.4) Tercera Forma Normal Fuerte (TFNF) o Forma Normal de Boyce-Codd

Una relación, a pesar de encontrarse en TFND, en algunos casos puede presentar inconvenientes de actualización. Consideremos como ejemplo la siguiente relación:

SUMINÍSTROS (número-proveedor, número-material, número-estante)

Suposiciones de Contexto

- La relación describe el número de estante en que se encuentra un determinado material suministrado por un determinado proveedor.
- En un estante únicamente puede almacenarse un sólo tipo de material.
- Un mismo material puede ser suministrado por más de un proveedor.
- Un mismo proveedor puede suministrar varios materiales a la empresa.
- Un material suministrado por un determinado proveedor se almacena siempre en el mismo estante.

SUMINISTROS

<u>número-proveedor</u>	<u>número-material</u>	número-estante
4	12	1
8	12	1
9	12	1
8	21	2
3	21	2
2	13	4
7	42	5
4	42	5
7	08	7
3	08	7
5	08	7
6	10	9

Podemos observar que SUMINISTROS se encuentra en SFND y TFND pues el único atributo no primo (número de estante) es dependiente funcional completo y directo de la clave concatenada número de proveedor-número de material. Sin embargo, presenta las siguientes anomalías.

Anomalías de actualización

Anomalías de alta:

- Si la empresa decidiera habilitar un estante para almacenar en él un nuevo material, no podrá dársele de alta a la información referida a éste, por ejemplo número de estante y número de material que contendrá, hasta tanto se presente un proveedor que suministre dicho material.
- Si no bastaran los estantes asignados para almacenar un determinado material ya existente en la empresa y se decidiera asignarle un nuevo estante, deberá dársele de alta tantas veces como proveedores sean los que lo suministran. Además, no podrá completarse esta operación, sino se tiene conocimiento de todos los números de dichos proveedores.

Anomalías de baja:

- Si se decidiera no comprar más un material a un determinado proveedor y éste fuera el único que lo suministrase hasta ese momento, al dársele de baja de la empresa, se perdería con él toda la información referida al estante; por ejemplo, número de material que contiene.
- Si se decidiera inhabilitar un estante, deberá dársele de baja tantas veces como proveedores sean los que suministran el material que almacena. Además, no podrá completarse esta operación si no se tiene conocimiento del número de material y los números de todos los proveedores que lo suministran. Por otra parte, en el supuesto caso que no exista más de un proveedor para dicho material, se perdería toda la información referida a estos (material y proveedor).

Anomalías de modificación:

Si cambiase alguna información referida al estante, por ejemplo número de material que contiene, deberá dársele de baja al estante en todos los proveedores del material anterior y dársele de alta en todos los proveedores del nuevo material.

Condición de anomalías

Las anomalías en relaciones como la del ejemplo, se dan por la presencia de grupos independientes.

Grupo independiente: grupo de atributos de R dependientes funcionales completos de un atributo no primo.

La existencia de un grupo independiente dentro de una relación ocasiona inconvenientes de actualización debido a la redundancia o repetición de los atributos no primos para más de un valor de la clave.

Definición de la TFNF

Para salvarlas anomalías ocasionadas por grupos independientes, Boyce creó la TFNF cuya definición es la siguiente:

Una relación R se encuentra en TFNF si para cada conjunto de atributos C de R, si cualquier atributo distinto de C depende funcionalmente de C, entonces todos los atributos de R son dependientes funcionales de C.

Cuando una relación no se encuentra en TFNF debe descomponerse en dos o más relaciones, donde los atributos que son dependientes funcionales de cada atributo o conjunto de atributos C, formen una relación aparte donde C sea clave.

Si reconsideramos el ejemplo, podemos comprobar que SUMINISTROS, a pesar de encontrarse en TFND, no se haya en la forma normal de Boyce-Codd, pues número de material es dependiente funcional de número de estante -ya que un estante a lo sumo puede almacenar un material- y número de proveedor no lo es; en este caso, número de estante es el atributo C de la definición. Por esta razón, SUMINISTROS debe descomponerse de la siguiente manera:

PROVEEDORES (**número-proveedor**, **número-estantes**)

ESTANTES (**número-estante**, número-material)

PROVEEDORES

número-proveedor

número-estante

4	1
8	1
9	1
8	2
3	2
2	4
7	5
4	5
7	7
3	7
5.	7
6	9

ESTANTES

<u>número-estante</u>	número-material
1	12
2	21
4	13
5	42
7	08
9	10

Podemos comprobar que las relaciones resultantes de la descomposición se encuentran en TFNF.

La TFNF según Sharman

Aunque de pasada ya adelantamos algo al explicar las formas normales anteriores, a continuación veremos una definición de Sharman para la TFNF, que resulta más fácil de comprender y sobretodo proporciona elementos conceptuales más claros y precisos para esta forma normal en particular y para el proceso de normalización en general.

La contribución de Sharman a la normalización de datos es el concepto de determinante.

Determinante: se denomina determinante de una relación a un atributo A ó a un conjunto redundante de ellos, que puede actuar como identificador único de uno o más atributos B dentro de la misma relación.

Para establecer una relación con los conceptos de Codd, también podemos definir a un determinante de la siguiente manera:

Determinante: dada una relación R, se dice que un atributo o conjunto de atributos A es determinante de uno o más atributos B, si y solo si cada uno de estos atributos B es dependiente funcional completo de A.

Para denotar un determinante utilizaremos las formas siguientes:

- Si A es determinante de B indicaremos $A \twoheadrightarrow B$; caso contrario, $A \not\rightarrow B$.
- Si A es determinante de varios atributos B simultáneamente, digamos B1, B2 y B3, entonces indicaremos $A \twoheadrightarrow (B1, B2, B3)$.
- Si A es determinante de un atributo compuesto de B, digamos B1 y B2, entonces indicaremos $A \twoheadrightarrow (B1, B2)$.
- Si un conjunto de atributos A, digamos A1, A2 y A3, es determinante de B, entonces indicaremos $(A1, A2, A3) \twoheadrightarrow B$.

La importancia del concepto de determinante es que permite detectar en una relación, atributos (*atributos A*) que identifican a otros atributos (*atributos B*) independientemente de

la clave. Es decir, atributos que no son claves pero cumplen una función de identificación para algún grupo de atributos -grupo independiente- que representa un concepto distinto al que describe la relación.

Sharman afirma que si un determinante está compuesto por más de un atributo A, éstos son no redundantes, pero en el sentido de que no pueden ser identificadores independientes del mismo conjunto de atributos B. Si consideremos la relación EMPLEADOS (legajo, documento, nombre, edad) donde solamente los atributos legajo y documento son únicos, aquí legajo $\rightarrow$ documento, nombre, edad) y documento $\rightarrow$ legajo, nombre, edad) pues legajo puede identificar de forma única e independiente a documento, nombre y edad, y de igual manera documento puede hacerlo con legajo, nombre y edad, pero al par (legajo, documento) $\rightarrow$ nombre, edad) ya que legajo y documento son redundantes, pero no en el sentido de que puedan repetirse -no ser únicos- para varios empleados, sino que cada uno por sí sólo identifica a los mismos valores de domicilio y edad; son identificadores redundantes; la función de identificación es la que está repetida. Con esto quiere expresar que un determinante, si es que éste existe dentro de una relación, es una clave única no redundante para uno o más de sus atributos y es el concepto en el que se basa para dar su definición de TFNF.

Definición: Una relación R se encuentra en TFNF si cada uno de sus determinantes es clave candidata.

Si una relación no cumple con esta definición, aquellos determinantes que no son claves junto a sus atributos dependientes, deben formar relaciones aparte donde dichos determinantes sean clave.

Por ejemplo: dada la relación R(a, b, c, d, e) donde $a \rightarrow b, c, d, e$ y $e \rightarrow c, d$, la misma no está en TFNF pues e es determinante y no es clave candidata; recordemos que para que un atributo ó un conjunto de ellos sea clave candidata de una relación, sus valores deben identificar unívocamente e independientemente a cada una de sus tuplas y por consiguiente, a todos sus atributos. Es decir, al igual que a, el atributo e debería ser determinante de todos los atributos restantes de la relación e $\rightarrow a, b, c, d$), pero como esto no sucede, R no está en TFNF y debe descomponerse formando con los atributos dependientes repetidos para cada determinante, relaciones aparte; esto es así: R1(a, b, e) y R2(e, c, d).

Observemos que el problema aquí no radica en que no pueda haber más de una clave dentro de una relación, sino, de existir éstas, todas ellas deben poseer las propiedades de una clave candidata. En relación a esto, podemos comprobar que la relación EMPLEADOS vista anteriormente, posee dos determinantes -número de legajo y número de documento- y los dos son claves candidatas, aunque por cierto, sólo una de ellas, en este caso número de legajo, es elegida como clave principal. Luego EMPLEADOS está en TFNF.

En contrapartida, la relación SUMINISTROS no está en TFNF pues estante $\rightarrow$ material y no es clave candidata. Por lo tanto, debe descomponerse formando con este par de atributos una relación aparte.

El concepto de determinante es de tanta importancia dentro de la normalización que podemos hablar de dos momentos: antes y después de Sharman. Decirnos esto porque realmente podemos olvidar completamente todo lo anterior referido a la PFN, SFN y TFND, a los atributos primos y no primos, a la dependencia total o parcial, a la dependencia transitiva y no transitiva, y llegar directamente a la TFNF. También, como

veremos más adelante, el concepto de determinante es tomado como referencia para el desarrollo de formas normales superiores.

Corolario de la TFNF

Una relación toda clave siempre está en TFNF.

Podemos demostrar este corolario por medio de los conceptos de Sharman:

Sí una relación es toda clave, entonces no posee atributos no primos y la única posibilidad de que exista un determinante distinto al que conforma la clave, es que éste se encuentre entre los mismos atributos primos que la componen. Probaremos ahora que esto no es posible.

Si partimos de la suposición de que en la clave principal de una relación, un atributo A es determinante de otro atributo B de la misma clave, como toda clave en sí misma es también un determinante, entonces B es redundante. Pero como por definición un determinante no posee atributos redundantes, luego la suposición anterior es falsa.

Con esto probamos que sí una relación es toda clave, no existe otro determinante que no sea la clave principal. Luego la relación siempre estará en TFNF.

2.5) La Cuarta Forma Normal (CFN)

Una relación, a pesar de encontrarse en TFNF y/o TFNF, en algunos casos puede presentar anomalías de actualización. Por ejemplo, consideremos la siguiente relación:

INVESTIGADORES (nombre, libro, proyecto)

Suposiciones de contexto

- La relación describe los libros y proyectos de un investigador.
- Un investigador puede ser autor de varios libros.
- Un libro puede tener como autores a varios investigadores.
- Un investigador puede participar en varios proyectos de investigación.
- En un proyecto participan varios investigadores.
- Los nombres de los investigadores no se repiten.

INVESTIGADORES

<u>nombre</u>	<u>libro</u>	<u>proyecto</u>
Juan Pérez	A	1
Juan Pérez	A	2
José López	B	1
José López	C	1
Raúl Juárez	D	2
Raúl Juárez	D	3
Raúl Juárez	E	2
Raúl Juárez	E	3
Mario Sánchez	D	2
Mario Sánchez	D	3

Podemos observar en INVESTIGADORES, que a raíz del tipo de relación N a M que asocia a los nombres con los libros por un lado y a los nombres con los proyectos por otro, ninguno de estos atributos por sí sólo, ni ningún par que sea una combinación de ellos, identifico unívocamente a ningún otro atributo dentro de la relación. Luego, el único determinante es la clave concatenada nombre-libro-proyecto, por lo que la relación está en TFNF. También podemos asegurar que INVESTIGADORES está en TFNF pues se trata de una relación todo clave. Sin embargo, presenta las siguientes anomalías de normalización.

Anomalías de actualización

Anomalías de alta:

- No podrá dársele de alta a un investigador si se conocen únicamente sus libros o sus proyectos.

Necesariamente deben conocerse estos dos grupos de atributos:

*Si un investigador no escribiera ningún libro, no podrá dársele de alta a la información referida a sus proyectos.

* Si un investigador no interviniese en ningún proyecto, no podrá dársele de alta a la información referida a sus libros.

- Cada vez que un investigador escriba un nuevo libro, deberá dársele de alta tantas veces como proyectos sean en los que trabaja. Además, no podrá completarse esta operación si no se conocen todos los números de dichos proyectos.

- Cada vez que un investigador emprende un nuevo proyecto, deberá dársele de alta tantas veces como libros sean de su autoría. Además, no podrá completarse esta operación, sino se conocen los títulos de todos sus libros.

Anomalías de baja:

-Si se decidiera sacar de circulación un libro perteneciente a un investigador determinado, deberá dársele de baja tantas veces como proyectos sean en los que participó: Además, no podrá completarse esta operación si no se conocen todos los números de dichos proyectos. Por otra parte, si el libro sacado de circulación hubiera sido el único ejemplar escrito por ese investigador, al darle de baja se perdería con él y sin posibilidad de conservarla -pues no posee otro libro-, toda la información referida a sus proyectos.

- Si un investigador renunciara a un proyecto, deberá dársele de baja tantas veces como libros tenga escritos. Además no podrá completarse esta operación sin o se conocen todos los títulos de dichos libros. Por otra parte, si el proyecto al cual renunciare fuera el único proyecto al que estaba afectado, al dársele de baja se perdería también y sin posibilidad de conservarla -pues no participa en otro proyecto-, toda la información referida a sus libros.

Anomalías de modificación:

- Si se decidiera cambiar el título de un libro perteneciente a un determinado autor -por ejemplo, por el de su traducción en inglés-, deberá modificarse este mismo dato, tantas veces como proyectos sean en los que participó.

- Si se decidiera cambiar el código de un proyecto en el que participa un determinado investigador, deberá modificarse este mismo dato, tantas veces como libros sean los que haya escrito.

Condición de anomalía

Las anomalías en relaciones tales como INVESTIGADORES, se dan por la presencia de grupos dependientes multivalor entre sus atributos. Para definir a estos grupos, previamente veremos el concepto de dependencia de valores múltiples.

Dependencia de valores múltiples: se dice que en una relación existe una dependencia de valores múltiples, si entre sus atributos existe por lo menos un atributo A y dos atributos B, digamos B1 y B2, ambos dependientes de A, donde los valores de A se relacionan con los valores de B2 a través de los valores de B1, o bien, donde los valores de A se relacionan con los valores de B1 a través de los valores de B2.

Una observación importante es que en una relación de dependencia multivalor, el orden de los atributos B dentro de la relación -suposición relativa- es indiferente. Podemos comprobar que intercambiando el orden de los atributos libro y proyecto en la relación INVESTIGADORES no se pierde ninguna información. Esto es así: INVESTIGADORES (nombre, proyecto, libro).

Grupos dependientes multivalor: Se llama así a aquellos grupos compuestos por atributos B de una relación, que definen una dependencia multivalor respecto de otro atributo A dentro de la misma.

Debemos destacar ahora, una observación por lo general ausente en los libros referidos al tema, y es que no toda dependencia de valores múltiples presente en una relación, necesariamente provoca inconvenientes de actualización. Podemos distinguir dentro de los grupos dependientes multivalor, a aquellos entre los cuales existe una dependencia funcional de aquellos en los que tal relación no existe. Luego, lógicamente, sólo estos últimos son los que provocan anomalías, por estar forzados a relacionarse sin que exista entre ellos dependencia funcional alguna. Esto se refleja en la redundancia de datos generada a raíz de la falta de independencia de dichos grupos. Si consideramos nuevamente la relación INVESTIGADORES, podemos observar que para cada investigador, cada uno de sus libros se repite tantas veces como proyectos sean en los que participó y a la vez, cada uno de sus proyectos tantas veces como libros sean de su autoría.

Basados en esta observación, también podemos clasificar a los grupos dependientes multivalor en dos tipos: triviales y no triviales. Un grupo trivial será aquél en el que la dependencia de valores múltiples en él definida, representa relaciones de dependencias funcionales de sus atributos. Por su parte, un grupo no trivial será aquél en el que la dependencia de valores múltiples en él definida, no representa relaciones de dependencias funcionales de sus atributos.

Definición de CFN

Para evitar las anomalías producidas por las dependencias multivalor, Zaniolo creó la CFN cuya definición es la siguiente:

Definición: Una relación se encuentra en CFN, si se encuentra en TFND ó TFNF y además no existe entre sus atributos, ninguna dependencia multivalor que no sea una relación de dependencias funcionales.

Considerando la clasificación hecha de los grupos dependientes multivalor, una definición alternativa de la CFN sería la siguiente:

Definición: Una relación se encuentra en CFN sino posee ningún grupo multivalor no trivial. Cuando una relación no se encuentra en CFN debe descomponerse en dos relaciones que verifiquen esta condición. La descomposición debe hacerse eliminando la dependencia multivalor y sin pérdida de información. Así, una relación que posea una dependencia multivalor definida entre un atributo o una colección de atributos A por un lado y los atributos o colecciones de atributos B1 y B2 por otro lado, debe descomponerse formando relaciones aparte con los pares (A, B1) y (A, B2).

Volviendo al ejemplo, podemos observar que la relación INVESTIGADORES no está en CFN pues existe una relación de dependencia multivalor con grupos no triviales, definida entre nombre del investigador por un lado -atributo A- con sus respectivos libros y proyectos por otro lado -atributos B1 y B2-. En consecuencia INVESTIGADORES debe descomponerse de la siguiente manera:

LIBROS-INVESTIGADORES (nombre-investigador, libro)

PROYECTOS-INVESTIGADORES (nombre-investigador, proyecto)

LIBROS-INVESTIGADORES

<u>nombre-investigador</u>	<u>libro</u>
Juan Pérez	A
José López	B
José López	C
Raúl Juárez	D
Raúl Juárez	E
Mario Sánchez	D

PROYECTOS-INVESTIGADORES

<u>nombre-investigador</u>	<u>proyecto</u>
Juan Pérez	1
Juan Pérez	2
José López	1
Raúl Juárez	2
Raúl Juárez	3
Mario Sánchez	2
Mario Sánchez	3

Podemos comprobar que las reacciones resultantes no presentan las anomalías indicadas por la CFN ya que los atributos libro (B1) y proyecto (B2) no repiten sus valores para cada valor de A.

La CFN según Robinson

Para Robinson, la forma de saber si una relación se encuentra en CFN es verificando si posee grupos de repetición independientes.

Grupos de repetición independientes: se llama así a aquellos atributos o conjunto de atributos - a tributos B- que se combinan de todas las maneras posibles en relación a otro a tributo o conjunto de atributos -atributos A- de la misma relación.

El nombre grupos de repetición independientes se debe a que representan grupos de repetición de la relación original no normalizada ya que son independientes entre sí; esto es, no existen dependencias funcionales entre ellos.

Una observación importante de Robinson, es que cuando una relación posee grupos de repetición independientes, presenta una redundancia de datos perjudicial e innecesaria. Perjudicial por ser el motivo de los inconvenientes de actualización planteados por la CFN e innecesaria, porque si para un atributo A se dan todas las combinaciones posibles entre los a tributos B, quiere decir que la relación entre estos últimos no es portadora de información; al contrario, sería portadora de información sino se presentarían todas las combinaciones. Si nos fijamos en el ejemplo, para un investigador se presentan todos los pares posibles entre sus libros y proyectos, lo cual no es información pues son conceptos independientes; el hecho que un investigador escriba o no libros no impide o no tiene nada que ver, con que trabaje o no en proyectos. En cambio sería información si pudieran faltar algunos pares; es decir, si un investigador con ciertos libros no podría trabajar en determinados proyectos y viceversa.

Basado en estos conceptos Robinson define a la CFN de la siguiente manera:

Definición: Una relación se encuentra en CFN si está en TFND o TFNF y además no posee ningún grupo de repetición independiente.

Podemos comprobar que bajo esta definición, la relación INVESTIGADORES no se encuentra en CFN pues los atributos libro y proyecto, al combinarse sus valores de todas las maneras posibles en relación a cada investigador, conforman grupos de repetición independientes. En consecuencia debemos practicar la descomposición antes indicada, donde las relaciones resultantes (INVESTIGADORES y PROYECTOS-INVESTIGADORES) están en CFN ya que sólo poseen dos atributos, motivo por el cual no pueden contener grupos de repetición independientes.

Es evidente que Robinson llama grupos de repetición independientes a los grupos dependientes multivalor no triviales; en este sentido no aporta nada nuevo. Sin embargo, desde el punto de vista de la práctica, el concepto de grupo de repetición independiente es importante, ya que permite comprobar si una relación está en CFN analizando el contenido de sus atributos. Resulta particularmente útil como método de prueba cuando el análisis semántico de los atributos no muestra claridad en sus relaciones de dependencia.

A juicio personal, los nombres de grupos triviales y no triviales son más adecuados que grupos de repetición independientes y grupos de repetición dependientes respectivamente, para marcar la diferencia entre ellos y poner énfasis en que estos últimos son los que realmente determinan la normalización de datos.

La CFN según Dean

Para Dean la forma de saber si una relación se encuentra en CFN es a través del concepto de multideterminante, definición que él creó y que es una versión generalizada del concepto de determinante de Sharman.

Si observamos la relación INVESTIGADORES podemos comprobar que si bien un investigador no determina -esto es, no identifica unívocamente- a un libro o un proyecto, sí determina a un conjunto de ellos. Es decir, conocido un investigador quedan simultánea y perfectamente identificados sus libros independientemente de sus proyectos y sus proyectos independientemente de sus libros. En este caso se dice que el atributo nombre -de un investigador se entiende- es multideterminante de los atributos libro y proyecto respectivamente, dentro de la misma relación. *Multideterminante*: Dada una relación, se dice que un atributo A es multideterminante de un atributo B, en presencia de un atributo C, si cada valor de A puede actuar como identificador único de un conjunto de valores de B, independientemente de los valores de C.

La definición vale también para grupos de atributos A, B o C.

Para denotar a un multideterminante emplearemos la misma simbología que para determinante, sólo que con una ligera modificación. Para expresar que A multidetermina a B utilizaremos una flecha de doble punta. Esto es así $A \longleftrightarrow B$. Caso contrario, $A \nleftrightarrow B$.

De la definición deducimos que para que en una relación exista un multideterminante por lo menos debe poseer tres atributos: un atributo A, otro B y otro C. Siempre que expresamos $A \longleftrightarrow B$, aunque no lo expresemos explícitamente, también hacemos referencia a otro atributo C, que está presente en la relación y es independiente de B.

Observemos que entre los conceptos de multideterminante y dependencia multivalor existe la misma correspondencia que con los conceptos de determinante y dependencia funcional completa para las formas normales anteriores. Esto es, decir que $A \longleftrightarrow B$ es equivalente a decir que B es dependiente multivalor de A. Además, si consideramos que B es monovalor en lugar de multivalor, entonces A identifica a un único valor de B, por lo que $A \longrightarrow B$ ó, igualmente, B es del todo dependiente de A. En este sentido, la dependencia funcional completa puede verse como un caso particular de la dependencia multivalor, o bien, el concepto de multideterminante como una generalización del concepto de determinante de Sharman. Por eso, siempre que $A \longrightarrow B$ entonces también $A \longleftrightarrow B$. Aunque la inversa, esto es, si $A \longrightarrow B$ entonces $A \nleftrightarrow B$, no siempre se cumple. Ejemplo: investigador $\longrightarrow$ libro pero investigador $\nleftrightarrow$ libro.

Otra observación importante es que si $A \longleftrightarrow B$ independientemente de C, entonces A y C no son independientes entre sí -no aparecen todas las combinaciones posibles entre todos los valores de y todos los valores de B-, por lo tanto $B \nleftrightarrow A$ independiente de C. Es decir, siempre que entre dos atributos de una relación se da una relación de multidependencia en un sentido, la misma relación en sentido contrario nunca se cumple. Todas estas observaciones son particularmente útiles para la práctica. Veamos ahora la definición de multideterminante de Dean.

Definición: Una relación R se encuentra en CFN si cada multideterminante, si es que existe alguno, es una clave candidata.

Podemos comprobar que bajo esta definición la relación INVESTIGADORES no está en CFN pues nombre de investigador s multideterminante de libros y proyectos y no es por sí sólo, una clave candidata.

En cambio las relaciones LIBROS-INVESTIGADORES y PROYECTOS-INVESTIGADORES si están en CFN pues al poseer estas únicamente dos atributos, no existe en ellas ningún multideterminante

Podemos observar en estos mismos ejemplos, que el concepto de multideterminante es efectivo aún cuando el conjunto de valores de B identificados por un valor de A, pueda solaparse con otros conjuntos de valores del mismo atributo B. En la relación INVESTIGADORES el conjunto de libros de un investigador determinado puede solaparse con conjuntos análogos de otros investigadores. Con esto probamos que la definición de Dean es válida independientemente de que la relación entre A y B sea 1 a N ó N a M.

Por último, la importancia de la definición de Dean es que capitaliza lo bueno y simple del concepto de determinante para llegar a una fórmula lógica que se aplica en forma directa y automáticamente produce relaciones en CFN.

2.6) La quinta forma normal

Al comienzo definimos a la normalización de datos como un proceso que descompone progresivamente una relación con problemas de actualización en otras relaciones estructuralmente más simples, que evitan dichos problemas. También la definimos como un proceso reversible refiriéndonos a que siempre puede reconstruirse la relación original después de cada descomposición. Con estos conceptos simplemente quisimos resaltar que el proceso de descomposición indicado por las formas normales es sin pérdida de información; es decir, la misma información, brindada por una relación antes de aplicarle una determinada forma normal, puede deducirse a partir de las relaciones que resultan de la descomposición indicada por esa forma normal.

Hasta ahora hemos supuesto simplemente que en cada etapa del proceso de normalización, una relación que no está en una forma normal determinada, solamente puede descomponerse sin pérdida en dos relaciones. Fagin, autor de la QFN, pone en duda esta suposición demuestra que algunas relaciones, aún encontrándose estas en CFN y por lógica, también en TFN, SFN y PFN, presentan problemas de actualización y no pueden descomponerse en dos pero si en tres o más relaciones, en un mismo paso de normalización y sin pérdida de información, alguna. Consideremos la siguiente relación:

CURSOS (curso, turno, aula, profesor)

Suposiciones del contexto

- La relación describe los datos de una academia de idiomas.
- La academia dicta varios cursos simultáneamente.
- Cada curso corresponde a un idioma en particular.
- Existen tres turnos: mañana, tarde y noche.
- Un mismo curso puede dictarse en más de un turno.
- En un mismo turno pueden dictarse más de un curso.
- Existen varias aulas disponibles.
- Cada curso tiene asignadas aulas fijas para todos sus turnos.
- En una misma aula pueden dictarse más de un curso, en igual o distinto turno.

- Cada curso tiene asignado un cuerpo de profesores especializados en el idioma que se dicte.
- Un profesor puede dictar más de un curso.

CURSOS

curso	turno	aula	profesor
Ingles	mañana	1	Pedro
Ingles	mañana	1	Adriana
Ingles	mañana	2	Pedro
Ingles	mañana	2	Adriana
Ingles	tarde	7	Pedro
Ingles	tarde	1	Adriana
Ingles	tarde	2	Pedro
Ingles	tarde	2	Adriana
Francés	tarde	2	Pedro
Francés	tarde	2	Adriana
Francés	tarde	2	Raúl
Francés	noche	2	Pedro
Francés	noche	2	Adriana
Francés	noche	2	Raúl

Como podemos observar, se trata de una relación en donde no existen dependencias funcionales -completas se entiende—, ya que debido al tipo de relación N a M en los pares (curso, turno), (curso, aula) y (curso, profesor), ninguno de sus atributos por sí sólo, ni ningún par o terna que sea una combinación de ellos puede identificar unívocamente a ningún otro atributo dentro de ella. De esta manera, el único determinante es la clave concatenada (curso, turno, aula, profesor), por lo que CURSOS está en TFNF.

Tampoco en la relación existen multideterminantes, por lo que también está en CFN. Observemos que si bien un curso puede identificar todos sus turnos independientemente de sus aulas y profesores, al descomponer la relación original en los pares (curso, turno) y (curso, (aula, profesor)), en este último par, una misma aula aparece más de una vez para un curso determinando, no cumpliéndose la regla de descomposición indicada por la CFN). Notemos que aquí el problema no radica en que la fórmula de la CFN no puede detectar la presencia de dependencias de valores múltiples, sino que no es suficiente un paso de normalización para eliminar todos los grupos multivalor (grupos de repetición independiente según Robinson). Si de la descomposición de una relación que no está en CFN a lo sumo surgen dos relaciones, entonces CURSOS necesitaría dos pasos de normalización, uno para descomponer la relación original en los pares (curso, turno) y (curso, (aula, profesor)), y otro para descomponer (curso, (aula, profesor)) en los pares (curso, aula) y (curso, profesor). El mismo problema se presenta si los pares escogidos para la descomposición hubieren sido (curso, aula) y (curso, (turno, profesor)) o bien (curso, profesor) y (curso, (turno, aula)). Por otro lado, tampoco ninguno de los atributos turno, aula o profesor por sí solos, ni ningún par o terna que sea una combinación de ellos, es multideterminante de ningún atributo o conjunto de atributos, porque si bien pueden identificar a un conjunto de valores de ellos, no lo hacen independientemente del resto de

los atributos de la relación. Ejemplo: si escogemos a turno como multideterminante, observamos que puede identificar a todos los cursos en él dictados, pero no lo hace independientemente de aula y profesor, puesto que existen aulas y profesores fijos para cada curso. En términos de Robinson curso no es independiente de aula y profesor porque no se dan todas las combinaciones posibles entre los valores de sus respectivos dominios. El mismo problema se presenta si los atributos escogidos como multideterminante hubieran sido aula o profesor.

Ahora bien, a pesar de que CURSOS está en TFNF y CFN, presenta las siguientes anomalías de actualización.

Anomalías de actualización

Anomalías de alta:

- No podrá dársele completamente de alta a un curso si no se conocen necesariamente todos sus turnos, todas sus aulas y todos sus profesores:

- *Si momentáneamente no se encuentran profesores para el dictado de un curso determinado, no podrá darse de alta a la información referida a sus turnos y aulas.

- *Si momentáneamente no se definen las aulas para el dictado de un curso determinado, no podrá darse de alta a la información referida a sus turnos y profesores.

- *Si momentáneamente no se definen los turnos para el dictado de un curso determinado, no podrá darse de alta a la información referida a sus aulas y profesores.

- Si un curso pasara a dictarse en un nuevo turno, deberá dársele de alta tantas veces como aulas estén asignadas para su dictado y a su vez, por cada aula, tantas veces como profesores lo dicten.

- Si a un curso se le asignara una nueva aula, deberá dársele de alta tantas veces como turnos posea y a su vez, por cada turno, tantas veces como profesores lo dicten.

- Si a un curso se le asignara un nuevo profesor, deberá dársele de alta tantas veces turnos posea y a su vez, por cada turno, tantas veces como aulas tenga asignadas.

Anomalías de Baja:

- Si se decidiera suspender el dictado de un curso en un turno determinado, deberá darse de baja tantas veces como aulas tenga asignadas y a su vez, por cada aula, tantas veces como profesores lo dicten. Además, no podrá completarse esta operación si no se conocen todos los valores de dichos atributos. Por otra parte, si el turno en cuestión hubiera sido el único asignado para ese curso, al darse de baja se perdería con él toda la información referida a sus aulas y profesores.

- Si se decidiera desafectar a un aula del dictado de un curso determinado, deberá darse de baja tantas veces como turnos posea y a su vez, por cada turno, tantas veces como profesores lo dicten. Además, no podrá completarse esta operación si no se conocen todos los valores de dichos atributos. Por otra parte, si el aula en cuestión hubiera sido la única asignada para el dictado de dicho curso, al darse de baja se perdería con ella, toda la información referida a sus turnos y profesores.

- Si un profesor renunciara al dictado de un curso determinado, deberá darse de baja tantas veces como turnos posea y a su vez, por cada turno, tantas veces como profesores lo dicten. Además no podrá completarse esta operación si no se conocen todos los valores de dichos atributos. Por otra parte, si el profesor en cuestión hubiera sido el único afectado al

dictado de dicho curso, al dársele de baja se perdería con él toda la información referida a sus turnos y aulas.

Condición de anomalías

Las anomalías en relaciones como la del ejemplo, se dan por la presencia de grupos join dependientes entre sus atributos. Para llegar a una definición de estos grupos previamente veremos el concepto de dependencia de join.

Dependencia de Join: Si una relación R se descompone por proyección en un conjunto no necesariamente disjunto de relaciones $R_1, R_2, \dots, R_n$, entonces R posee una dependencia de join, si R es un join apropiado de $R_1, R_2, \dots, R_n$.

Grupos join dependientes: llamaremos así a aquellos grupos de atributos que definen una dependencia de join dentro de una relación. 3

La presencia de grupos join dependientes dentro de una relación ocasiona problemas de actualización cuando son los causantes de alguna redundancia de datos. En la relación CURSOS, cada curso se repite para todos sus 'turnos, cada turno para todas sus aulas y cada aula para todos sus profesores.

Definición de QFN

Para evitar las anomalías provocadas por los grupos join dependientes molestos Fagín creó la QFN cuya definición es la siguiente:

Definición: Una relación está en QFN si todas las dependencias de join definidas entre sus atributos, si es que éstas existen, son las que resultan de combinaciones de dependencias funcionales en las que el determinante es una clave candidata.

Cuando una relación no está en QFN debe descomponerse en dos o más relaciones que verifiquen esta condición. La descomposición debe hacerse eliminando las dependencias de join molestas por medio de sus proyecciones. En el ejemplo, CURSOS no está en QFN pues contiene una dependencia de join definida entre sus atributos, que resulta de la combinación de dependencias funcionales en las que curso es determinante y no es clave candidata. Por esta razón, debe descomponerse de la siguiente manera:

CURSOS-TURNOS (curso, turno)

CURSOS-AULAS (curso, aula)

CURSOS-PROFESORES (curso, profesor)

Un esquema ampliado de estas relaciones sería:

CURSOS-TURNOS

<u>curso</u>	<u>turno</u>
Ingles	mañana
Ingles	tarde
Francés	tarde
Francés	noche

CURSOS-AULAS

<u>curso</u>	<u>aula</u>
Ingles	1
Ingles	2
Francés	2

CURSOS-PROFESORES

<u>curso</u>	<u>profesor</u>
Ingles	Pedro
Ingles	Adriana
Francés	Pedro
Francés	Adriana
Francés	Raúl

Podemos comprobar que las relaciones resultantes no definen ninguna dependencia de join, por lo tanto se encuentran en QFN.

Observemos que el ejemplo apuntado no presenta otro inconveniente que una dependencia de valores múltiples, sólo que con más de un grupo multivalor entre sus atributos. Para este tipo de relaciones la aplicación de la CFN no da resultado porque no elimina en un sólo paso de normalización las condiciones que motivan su empleo; esto es, las dependencias multivalor. Esto, prueba que las dependencias multivalor son un caso particular de las dependencias de join y por ende, que toda relación en QFN también lo está en CFN.

A continuación detallaremos un enfoque distinto de la QFN que clarifica el concepto de dependencia de join y el motivo de ésta forma normal.

La QFN según Deen

Para dar su definición de la QFN Deen se basa en una clasificación que él hace de las dependencias de join, la cual le permite diferenciar aquellas dependencias de join molestas de aquellas que no lo son. Dicha clasificación distingue dos tipos de dependencias de join: 1) triviales y 2) no triviales.

Dependencias de join triviales: Una dependencia de join es trivial si sus proyecciones están basadas en claves candidatas. Ejemplo, consideremos la siguiente relación:

PERSONAS (documento, nombre, sexo, edad)

En PERSONAS suponemos que los nombres no se repiten, por lo tanto contamos con dos claves candidatas documento y nombre. Ahora bien, esta misma relación puede descomponerse en las siguientes proyecciones:

- | | | |
|------------------------------------|-------------------------------------|-------------------------------|
| 1) R1 (<u>documento</u> , nombre) | R2 (<u>documento</u> , sexo) | R3 (<u>documento</u> , edad) |
| 2) R1 (<u>documento</u> , nombre) | R2 (<u>documento</u> , sexo, edad) | |
| 3) R1 (<u>documento</u> , nombre) | R2 (<u>nombre</u> , sexo, edad) | |
| 4) R1 (<u>nombre</u> , documento) | R2 (<u>nombre</u> , sexo) | R3 (<u>nombre</u> , edad) |

Podemos comprobar que todos estos casos satisfacen una dependencia de join porque las proyecciones basadas en cualquiera de las dos claves candidatas o en alguna combinación de ellas recomponen la relación original.

Dependencias de join no triviales: Una dependencia de join es no trivial si sus proyecciones no están basadas en claves candidatas. Son ejemplos de ellas, las dependencias de valores múltiples con más de un grupo multivalor, tales como la definida en la relación CURSOS vista anteriormente y las dependencias mutuas de Nicolás que veremos más adelante en la relación PROYECTOS.

Definición

Si bien es cierto que por definición una relación cumple una dependencia de join si puede descomponerse sin pérdida de información en un conjunto apropiado de proyecciones, también es cierto que no toda descomposición tiene sentido practicarla. Precisamente, el análisis que Deen hace de la QFN está centrado en la observación de que las dependencias de join basadas en claves candidatas no son importantes pues no determinan la normalización. Así, toda relación R que posea n atributos y con al menos una clave candidata simple, siempre podrá descomponerse en un conjunto de n-1 relaciones binarias R1,R2,...,Rn-1, en las que cada una contendrá a la clave candidata y otro atributo, de modo tal que R sea un join apropiado de ellas. De igual manera, toda relación R presentará una dependencia de join si cada una de las proyecciones R1,R2,..., Rn en que pueda descomponerse, contiene una clave candidata de R. Es fácil comprender que tales dependencias de join no guardan ninguna relevancia para la normalización de datos pues no solucionan ningún inconveniente de actualización. Prueba de ello es que sus proyecciones no eliminan ni reducen ninguna redundancia de datos de la relación original. Por esta razón no son tenidas en cuenta para la normalización de datos y de allí el nombre de triviales.

Por su parte, el segundo tipo de dependencias de join es no trivial pues determina la normalización de datos. Con esto queremos expresar que se consigue la QFN cuando una relación no puede descomponerse más sin pérdida de información por medio de proyecciones no triviales; esto es, por medio de proyecciones no basadas en claves candidatas. La formalización de esta regla sería:

Definición: Una relación A está en QFN sino presenta ninguna dependencia de join no trivial. Consideremos la siguiente relación:

PROYECTOS (profesional, proyecto, firma)

Suposiciones del contexto

- La relación describe a profesionales que trabajan en distintos proyectos representando a firmas determinadas.
- Se cumple la siguiente regla simétrica: Si un profesional A trabaja en un proyecto X y éste pertenece a una firma Z que participa en dicho proyecto, entonces el profesional A trabaja en el proyecto X representando a la firma Z.
- Un mismo profesional puede pertenecer a más de una firma y trabajar en un mismo proyecto representándolas a todas ellas simultáneamente.
- No necesariamente un profesional trabaja en todos los proyectos en que intervienen cada una de las firmas a las que pertenece.
- No necesariamente una firma participe en todos los proyectos que se llevan a cabo. Un esquema ampliado de la relación sería:

PROYECTOS

<u>profesional</u>	<u>proyecto</u>	<u>firma</u>
Alejandra	P1	XX
Alejandra	P2	YY
Pedro	P1	YY
Alejandra	P1	YY

Podemos comprobar que la relación PROYECTOS se encuentra en PFN, SFN, TFN y CFN, pues puede representarse como una tabla bidimensional, solamente posee atributos

primos, el único determinante es la clave concatenada de los tres atributos que posee la relación y tampoco posee grupos dependientes multivalor, ya que no necesariamente un profesional trabaja en todos los proyectos en que intervienen las firmas a las que pertenece, ni una firma participa en todos los proyectos que se llevan a cabo. Sin embargo, la relación presenta las siguientes anomalías de actualización.

Anomalías de actualización

Anomalías de alta:

- Si se incorporara un profesional a un proyecto, deberá dársele de alta tantas veces como firmas sean a las que representará en dicho proyecto.
- Si una firma determinada decidiera participar en un proyecto, deberá dársele de alta tantas veces como profesionales dependientes suyos sean asignados para trabajar en dicho proyecto.
- Si una firma incorporara un nuevo profesional, no podría dársele de alta hasta tanto sea asignado a alguno de sus proyectos.
- Si una firma incorporara un nuevo profesional, deberá dársele de alta tantas veces como proyectos sean en los que trabajará representándola.

Anomalías de baja:

- Si un profesional renunciara a un proyecto, deberá dársele de baja tantas veces como firmas sean a las que representaba en dicho proyecto.
- Si un profesional renunciara a una firma, deberá dársele de baja tantas veces como proyectos sean en los que intervino representándola.
- Si una firma renunciara a un proyecto, deberá dársele de baja tantas veces como profesionales suyos trabajen en dicho proyecto representándola.

Anomalías de modificación:

- Si cambiara el código de un proyecto:
 - * Por cada investigador participante deberá modificarse este mismo dato tantas veces como firmas represente; o bien,
 - * Por cada firma participante deberá modificarse este mismo dato tantas veces como profesional/es la representen.
- Si cambiara el nombre de una firma:
 - * Por cada investigador perteneciente a ella deberá modificarse este mismo dato tantas veces como en proyectos trabaje representándola. O bien,
 - * Por cada proyecto en que esta intervenga deberá modificarse este mismo dato tantas veces como profesionales la representen.

Si aplicamos la definición de Deen comprobamos que a pesar de que la relación PROYECTOS está en CFN, no está en QFN pues existe en ella una dependencia de join no trivial definida por las siguientes proyecciones:


R1 (profesional, proyecto)

R2 (proyecto, firma)

R3 (firma, profesional)

El hecho que necesitemos tres proyecciones en lugar de dos, puede comprobarse reconstruyendo la relación original a partir del join de las proyecciones R1, R2 y R3.

Un esquema ampliado de esto sería el siguiente:



Es fácil comprobar en el gráfico que se satisface una dependencia de join pues PROYECTOS es un Join apropiado de R1, R2 y R3. En un primer paso obtenemos el join $(R1 * R2)$ y luego, con este resultado obtenemos el join $((R1, R2) * R3)$ que recompone la relación original. Notemos que para el primer join podríamos haber seleccionado R1 y R3 o bien R2 y R3 sin que el resultado final se modifique en absoluto. Cualesquiera sea la selección hecha, siempre con el primer join obtendremos una copia exacta de la relación original más una tupía espuria (falsa), que luego con el segundo join es eliminada. Por otra parte, también podemos comprobar que se trata de una dependencia de join no trivial pues sus proyecciones no están basadas en claves candidatas de la relación original -recordemos que la relación posee una única clave que resulta de la concatenación de todos sus atributos-. Por lo tanto, PROYECTOS no está en QFN y debe descomponerse en las proyecciones R1, R2 y R3 que definen la dependencia de join indicada. Luego, dichas relaciones si están en QFN -ya que no poseen ninguna dependencia de join no trivial- y no aceptan ninguna descomposición.

Cabe observar que el inconveniente presentado por la relación PROYECTOS es que tiene definida una dependencia funcional simétrica entre sus atributos. Si no existiera tal dependencia, es decir, si un profesional pudiera trabajar en cualquier proyecto independientemente de sí las firmas a las pertenece participan en dicho proyecto, entonces

PROYECTOS no cumpliría ninguna dependencia de join no trivial y se encontraría en QFN. La gran desventaja de la QFN es que su definición no proporciona ninguna técnica o recurso palpable que permita detectar las dependencias funcionales simétricas de primera instancia. Esto obliga muchas veces, especialmente en relaciones con un número elevado de atributos, a llevarlas relaciones primero hasta la CFN, para recién intentar aplicar la QFN, a pesar de que esta última es de aplicación directa

En cierta forma, todo esto se debe a que el concepto de dependencia de join en que se basa la QFN, a diferencia de los conceptos de dependencia funcional y dependencia multivalor en que se basan la TFNF y CFN, no tiene una interpretación directa en el mundo real. En la TFNF y CFN podemos identificar fácilmente determinantes y multideterminantes y con forme a ellos producirla descomposición que corresponda en cada caso, en cambio en la QFN no queda otro recurso que sacar en limpio todas las claves candidatas y todas las dependencias de join, para recién determinar si alguna de ellas es no trivial, Obviamente, esta tarea no es simple y tampoco segura porque la búsqueda de dependencias simétricas es hecha intuitivamente.

Corolario de la QFN

- Toda relación en CFN que no posea dependencias de valores múltiples con más de un grupo multivalor ni dependencias funcionales simétricas, de hecho, también está en QFN.
- La QFN es la última forma normal considerando a la proyección y el join como los únicos operadores legales.

2.7) Síntesis del proceso de normalización de datos

- Para la aplicación de una forma normal determinada es preciso que la relación en cuestión se encuentre en las formas normales inferiores, con excepción de la TFNF, CFN y QFN, para las cuales existen -fuera de la técnica tradicional- fórmulas de aplicación directa.
- El proceso de normalización de datos está basado en el análisis de tres tipos diferentes de relaciones: las dependencias funcionales de Codd para las PFN, SFN, TFND y TFNF, las dependencias multivalor de Zaniolo para la CFN y las dependencias de join de Fagin para la QFN.
- Las dependencias funcionales son un caso particular de las dependencias multivalor y estas a su vez, un caso particular de las dependencias de join, que es la forma más general de dependencia.
- Basándonos en el punto anterior, una relación en una forma normal determinada, también lo está en las formas normales inferiores, pero no necesariamente en las formas normales superiores.
- En todos los casos, la descomposición indicada por una forma normal es sin pérdida de información.
- La TFNF se consigue por descomposición sin pérdida sobre determinantes, la CFN se consigue por descomposición sin pérdida sobre multideterminantes y la QFN se consigue cuando una relación no puede descomponerse más sin pérdida, excepto por proyecciones triviales.

- La QFN es la última forma normal considerando a la proyección y el join como los únicos operadores legales.
- La QFN no sólo es la última forma normal sino un súper conjunto de la TFNF y CFN, ya que en este estado de normalización no existen determinantes ni multideterminantes que no sean claves candidatas.